Apache Spark

Osnove, osobine, primeri

Apache Spark

- Objedinjeno radno okruženje za analizu velike količine podataka
- Kombinuje SQL, tokove podataka i kompleksnu analitiku (mašinsko učenje)
- Radi nad različitim tipovima skladišta podataka
- Visoka performansa rada prilikom paketne i obrade tokova podataka
- Korisničke programe moguće je pisati u
  - Scala (izvorno)
  - Java
  - Python
  - SQL
  - R

Lightning-fast unified analytics engine

Spark - arhitektura

- Master/slave arhitektura
- Osnovni Spark moduli
  - Spark Core
  - Spark SQL
  - Spark Streaming
  - MLib
  - GraphX

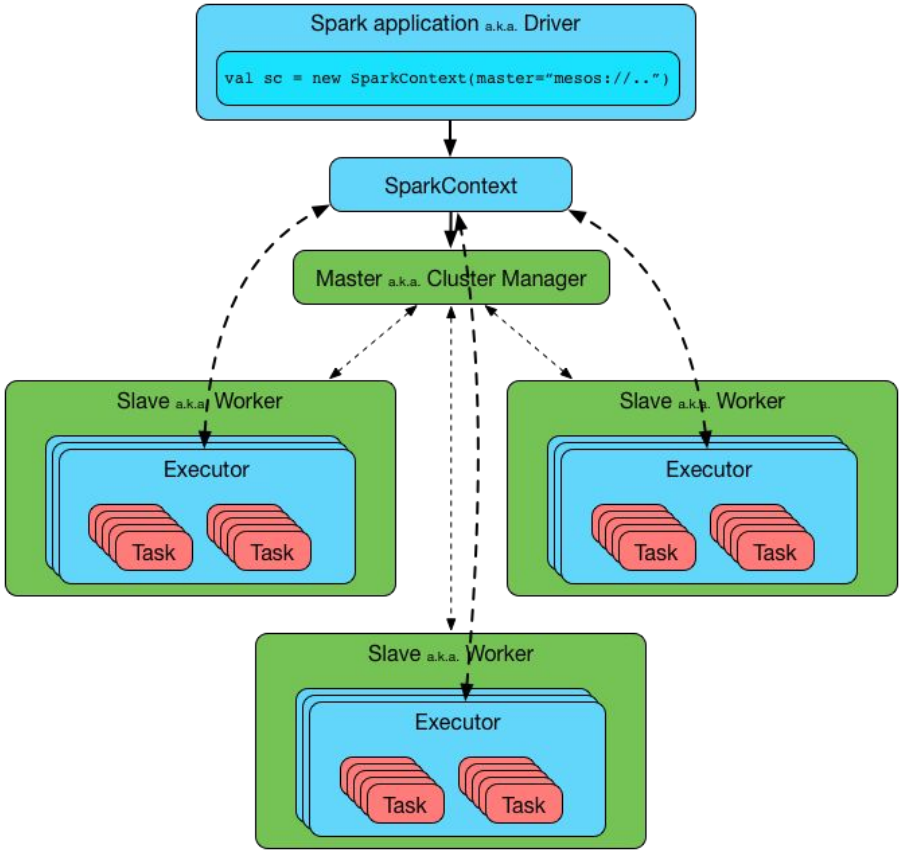

Spark - arhitektura

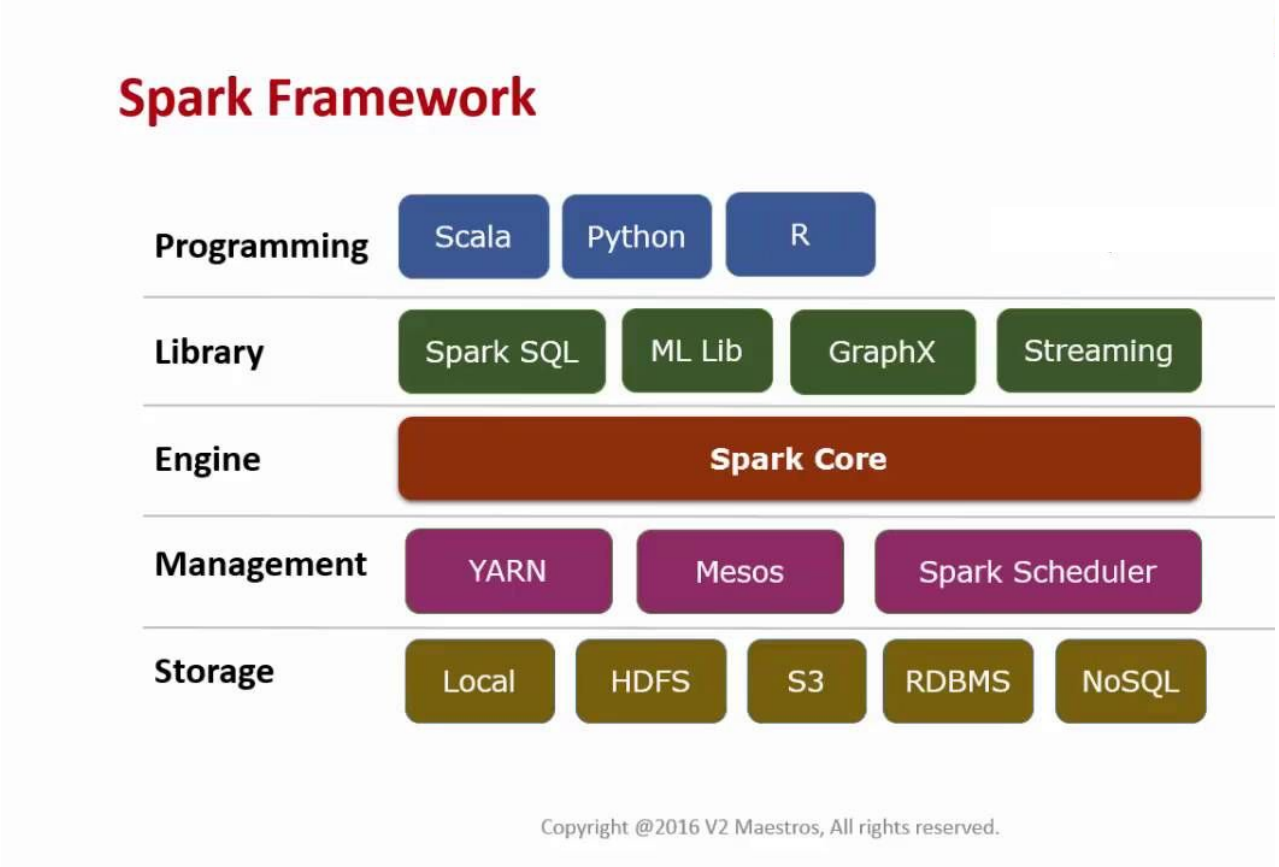

Docker compose

- Servisi
  - HDFS
    - Namenode
    - Datanode x 2
  - Spark
    - Spark-master
    - Spark-worker x 2
  - Opciono:
    - Hue - Web-bazirani file-browser za HDFS
    - Spark-notebook - Web-interfejs za pokretanje Spark aplikacija

RDD

- Problem sa interativnim *map-reduce* programima
  - Sporo deljenje memorije
  - Upis na disk nakon svakog *map-reduce* koraka
  - Previše (za krajnji rezultat) nepotrebnih I/O operacija

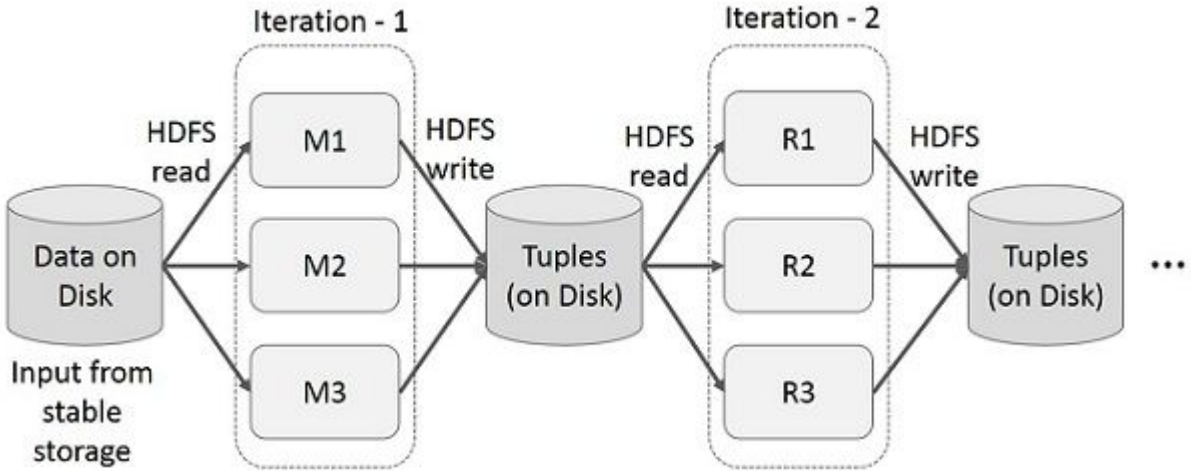

RDD

- *Resilient Distributed Datasets* (RDD)
  - Kolekcija elemenata distribuirana po čvorovima klastera koju je moguće obrađivati paralelno u radnoj memoriji
  - Eliminacija velikog broja I/O poziva značajno povećava brzinu izvršavanja iterativnih *map-reduce* programa

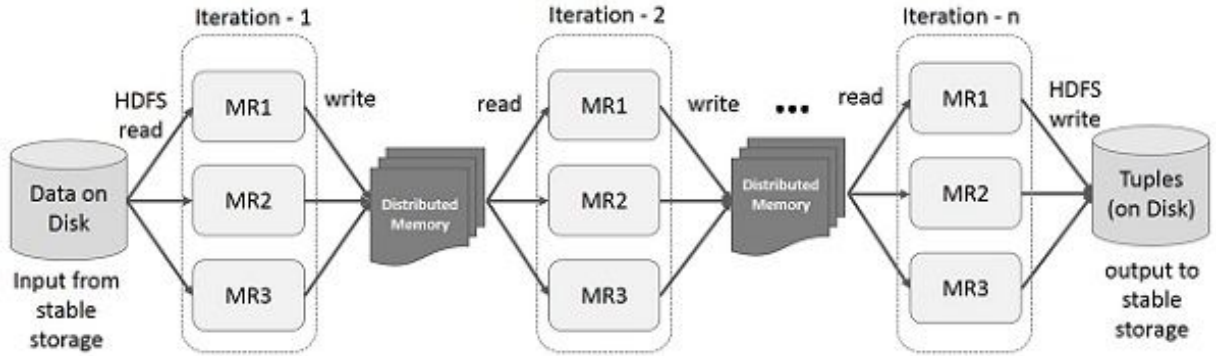

RDD - osnove

- Fundametalni koncept u Spark-u
- *Resilient Distributed Dataset*
  - *Resilient* - otporan na greške sa mogućnošću nadoknađivanja oštećenih/izgubljenih delova strukture podataka
  - *Distributed* - podaci su smeštni na više čvorova u klasteru
  - *Dataset* - predstavlja skup slogova (zapisa) u bilo kom formatu
    - najčešće JSON, CSV, tekstuelni format

RDD - mehanizmi

- Čitanje
  - Celokupnog dataseta (coarse-grained)
  - Pojedinačnih elemenata (fine-grained)
- Pisanje
  - Celokupnog dataseta (coarse-grained)
- Konzistentnost
  - Na visokom nivou s obzirom da je RDD nepromenljiv
- Oporavak od grešaka
  - Omogućen upotrebom usmerenih acikličnih grafova operacija (DAG)

RDD - osobine

- *In-memory computation*
- Odložena (*lazy*) evaluacija
- Otpornost na greške
- Nepromenljivost
- Particionisanje
- Mogućnost perzistovanja
- Operacije na celokupnim setom podataka

Deljene promenljive

- Spark nudi dva tipa deljenih promenljivih između zadataka koji se izvršavaju na različitim čvorovima klastera
  - *Broadcast* varijable
    - Keširane *read-only* promenljive na svakom čvoru
    - Često se koriste da svaki čvor dobije svoju kopiju nekog ulaznog skupa podataka
  - Akumulatori
    - Njihova vrednost može samo biti uvećana
    - Često se koriste za implementaciju agregacionih funkcija (npr. brojanje, suma)

RDD - operacije

- Transformacije
  - Od postojećeg RDD formiraju novi
  - Uske (*pipelining*)
    - Nad jednom particijom
  - Široke (*shuffle*)
    - Zahtevaju više particija
- Akcije
  - daju neki rezultat
    - Sve do nailaska na akciju Spark odlaže isvršenje transfomacija

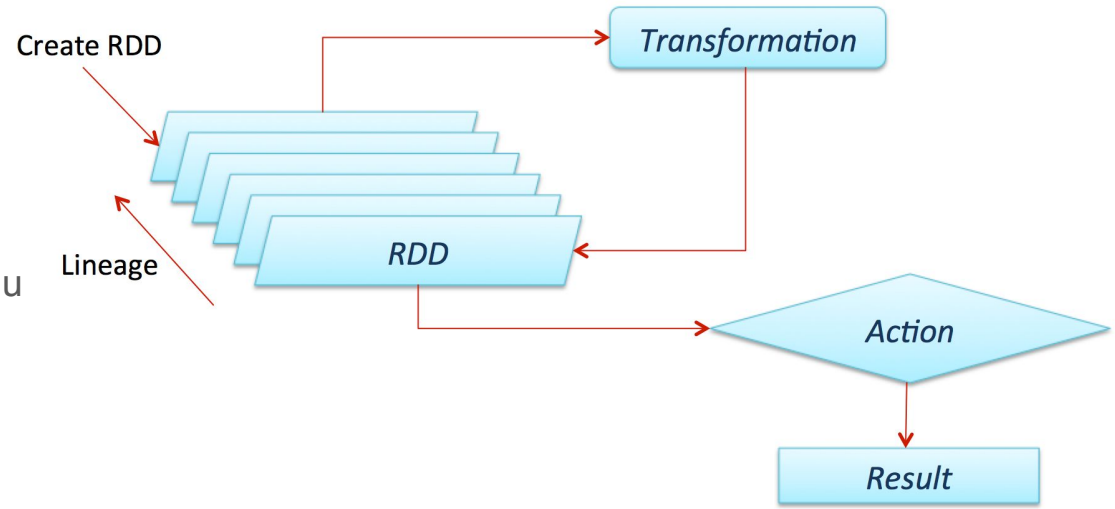

RDD - operacije

- Transformacije
  - Uske
    - Map
    - FlatMap
    - MapPartition
    - Filter
    - Sample
    - Union
  - Široke
    - Intersection
    - Distinct
    - ReduceByKey
    - AggregateByKey
    - SortByKey
    - Join
    - Cartesian
    - Repartition
    - Coalesce
- Akcije
  - Count
  - CountByKey
  - Collect
  - First
  - Take
  - Top
  - CountByValue
  - Reduce
  - Fold
  - Aggregate
  - Foreach
  - SaveAsText
  - SaveAsSequenceFile
  - SaveAsObjectFile

RDD - ograničenja

- Nepostojanje ugrađenog optimizatora operacija sa RDD
  - Sva optimizacija prepuštena programeru
- Obrada strukturiranih podataka
  - RDD nema mehanizme da prepozna šemu ulaznog skupa podataka
- Performansa
  - RDD su JVM objekti i često uzrokuju preteranu upotrebu Garbage Collectora i Java serijalizacije
- Skladištenje
  - U slučaju da RDD ne može stati u radnu memoriju, sledi smeštanje jednog dela na disk

RDD - Primeri

- Brojanje reči
- Prosečna dužina reči
- Sve reči diže od *X* slova koje se pojavljuju više od *Y* puta
- Unija i presek
- Uklanjanje duplikata
- Grupisanje i sortiranje po ključu
- Spajanje
- Upotreba deljenih varijabli

Spark SQL

- Integriše relacioni način procesiranja podataka sa Spark funkcionalnom paradigmom
- Predstavlja Spark modul za procesiranje strukturiranih podataka
- Premošćava jaz između RDD koncepta i relacione tabele
- Deklarativni pristup na dva načina
  - DataFrame
  - Datasets API
    - Java i Scala

Spark SQL - osobine

- Integrisanost
  - SQL upiti sa Spark programima
- Unificiran pristup podacima
  - Izvori podataka mogu biti Hive, Parquet, JSON, JDBC, …
- Kompatibilnost
  - Moguće pokretati Hive upite
- Standardni mehanizmi konekcije
  - Moguće se konektovati preko JDBC ili ODBC
- Optimizacija
  - Postoji ugrađeni optimizator upita

Spark SQL DataFrame

- Struktura podataka organizovana u imenovane tabele
  - Slično kao koncept R dataframe ili Python pandas dataframe
- Predstavlja reprezentaciju tabele iz relacione baze podataka u Spark SQL-u
- Poseduje šemu
  - Svaka kolona ima ime, tip i indikator dozvole NULL vrednosti
  - Moguće je programski definiti šemu
- Moguće je kreirati DataFrame od RDD
- DataFrame API se može koristiti u
  - Scala
  - Java
  - Python
  - R

Spark SQL DataFrame - osobine

- Oslanja se na RDD i od njega nasleđuje
  - Nepromenljivost
  - Distribuirano izvršavanje u radnoj memoriji
  - Otpornost na otkaze
- Poboljšanja u odnosu na RDD
  - Efikasnije upravljanje memorijom (*Custom Memory Management*)
  - Optimizacija upita
- Daje se prednost *DataFrame*-u u odnosu na RDD prilikom obrade strukturiranih podataka

Spark SQL DataFrame - primeri

- https://spark.apache.org/docs/latest/sql-getting-started.html

Spark SQL DataFrame - Optimizator upita

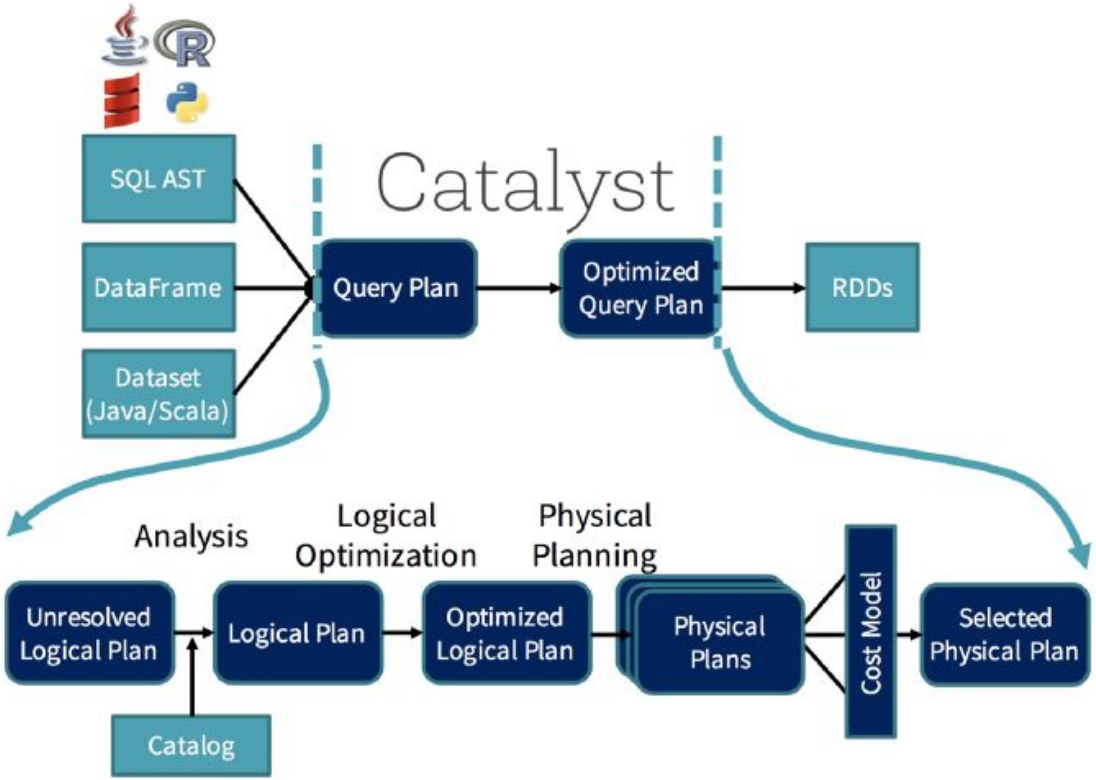

DataFrame - kreiranje

- Od RDD-ova - toDF()
- Od listi - toDF()
- Od lokalnih ili HDFS datoteka
  - CSV - `spark.read.csv(path)`
  - Text - `spark.read.text(path)`
  - JSON - `spark.read.json(path)`
  - Parquet - `spark.read.parquet(path)`
- Preko JDBC konekcije
  - `spark.read.format("jdbc").option().load()`

DataFrame - dodavanje i uklanjanje kolona

- Dodavanje nove kolone
  - `df.withColumn("Country", lit("USA"))`
  - `df.withColumn("salary", col("salary")*100)`
  - `df.withColumn("salary", col("salary").cast("Integer"))`
- Preimenovanje kolone
  - `df.withColumnRenamed("gender","sex")`
- Uklanjanje kolone
  - `df.drop("CopiedColumn")`

DataFrame - filtriranje

- Filtriranje
  - `df.filter(df["state"] == "OH").show(truncate=False)`
  - `df.filter("gender == 'M'").show(truncate=False)`
  - `df.where("gender == 'M'").show(truncate=False)`
  - `df.filter(df("state") == "OH" & df("gender") == "M").show(truncate=False)`
- Uslov može biti zadat kao
  - Poređenje
  - String sa logičkim izrazom
  - Kompleksan logički uslov

DataFrame - tipovi podataka i konverzije

- Podržani tipovi podataka
  - Numeric tipovi
    - ByteType, ShortType, IntegerType, LongType
    - FloatType, DoubleType, DecimalType
  - Stringovi - StringType
  - Binarni - BinaryType
  - Logički - BooleanType
  - Datumski - TimestampType, DateType
  - Kompleksni tipovi
    - ArrayType
    - MapType
    - StructType

DataFrame - pivoting

- Rotiranje podataka iz jedne u više kolona po vrednostima
  - df.groupBy("Product").pivot("Country").sum("Amount")
  - Za svaku vrednost iz kolune Country napraviće se posebna kolona
- Depivotiranje
  - pivotDF.select(col("Product"),
    expr("stack(3, 'Canada', Canada, 'China', China,
    'Mexico', Mexico) as (Country,Total)")).where("Total is not null")
  - Stack funkcija od kolona i vrednosti u njima prvi redove

DataFrame - spajanje

- Tipovi spajanja
  - INNER, LEFT OUTER, RIGHT OUTER, LEFT ANTI, LEFT SEMI, CROSS, SELF
- Optimizacija spajanja
  - BROADCAST, MERGE, SHUFFLE_HASH and SHUFFLE_REPLICATE_NL
  - Hint
    - SELECT /*+ COALESCE(3) */ * FROM t
    - SELECT /*+ REPARTITION(3) */ * FROM t
    - SELECT /*+ REPARTITION(c) */ * FROM t
    - SELECT /*+ REPARTITION(3, c) */ * FROM t
    - SELECT /*+ REPARTITION_BY_RANGE(c) */ * FROM t
    - SELECT /*+ REPARTITION_BY_RANGE(3, c) */ * FROM t
  - “Zakrivljenost” (skewness) podataka - neuniformna distribucija vrednosti ključa
    - “Soljenje” (salting) ključa dodavanjem još jedne kolone u ključ radi ravnomernijeg particionisanja

DataFrame - perzistencija

- Čuvanje međurezultata
- Korišćenje međurezultata u uzastopnim operacijama
- cache()
  - MEMORY_AND_DISK - DataFrame
  - MEMORY_ONLY - RDD
- persist()
  - MEMORY_ONLY
  - MEMORY_AND_DISK
  - MEMORY_ONLY_SER
  - MEMORY_AND_DISK_SER
  - DISK_ONLY
  - MEMORY_ONLY_2
  - MEMORY_AND_DISK_2

DataFrame - agregacije

- Agregacione funkcije
  - sum, avg, min, max, count, countDistinct
  - first, last, mean, stddev, variance, approx_count_distinct
- Sa ili bez groupBy
  - ```
    df.groupBy("department")
        .agg(
          sum("salary").as("sum_salary"),
          avg("salary").as("avg_salary"),
          sum("bonus").as("sum_bonus"),
          max("bonus").as("max_bonus"))
        .show(false)
    ```
    ```

DataFrame - analitičke funkcije

- Definisanje prozora - Window
  - windowSpec = Window.partitionBy("department").orderBy("salary")
- Rangiranje
  - row_number, rank, percent_rank, dense_rank, ntile
- Analiticke funkcije
  - cume_dist, lead, lag
- Agregacione funkcije

Zadatak

- Preuzeti CSV datoteku https://data.gov.rs/sr/datasets/zagadjivachi-chvrstim-otpadom/
- Kopirati je na proizvoljnu HDFS lokaciju
- Napisati Spark aplikaciju koja učitava sadržak CSV datoteke u dataframe
  - Separator je ;
  - Encoding je Windows-1250
- Ispisati shemu učitanog dataframe-a
- Ispisati prvih 5 redova
- Ispisati sve različite opštine

Zadatak

- Ispisati preduzeća koja su 2015 proizvela preko 10 tona otpada
- Ispisati sve pretežne delatnosti sa preko 10 postrojenja
- Ispisati top 5 zagađivača u oblasti *Proizvodnja komunikacione opreme*
- Ispisati najveće zagađivače po gradovima
- Kolone sa 2010-2017 pretvoriti u jednu kolonu *godina*, a iznos količine otpada u kolinu *kolicina*
- Ispisati preduzeća (PIB + Postrojenje) sa najvećim skokom proizvodnje neke vrste otpada (Indeksni broj) u odnosu na prethodnu godinu
- Rezultat sačuvati u relacionu bazu podataka (npr. MySQL, PostgreSQL)
    - Proširiti docker-compose kontejnerom za bazu podataka
    - Koristeći uputstvo, sadržaj dataframe-a upisati u tabelu u bazi podataka

Spark MLlib

- MLlib - Sparkova biblioteka za mašinsko učenje zasnovana na RDD
  - RDD API danas zastareo pa ga nije preporučljivo koristiti
- DataFrame-based API - preporučeno za korišćenje - Spark ML
- Osnovni koncepti
  - DataFrame - ulazni dataset
  - Transformer - algoritam za transformaciju DataFrame-a (npr. dodavanje kolone sa predikcijama)
  - Estimator - algoritam za kreiranje transformatora (npr. fabrika modela)
  - Pipeline - estimatori i transformatori povezani u neki smilsen tok
  - Parameter - podešavanja estimatora i transformatora

Spark MLlib

- Osnovne statistike
  - Srednja vrednost, varijansa, kovarijsna, korelacija, testiranje hipoteze
- Klasifikacija i regresija
  - Linearni modeli, naivni Bayes, stabla odlučivanja, ansambli stabala
- Klasterovanje
  - k-means, Gaussian Mixture
- Kolaborativno filtriranje
- Redukcija dimenzionalnosti
  - SVD, PCA